Lecture 19

- 当1 Singular value decomposition (奇异值分解)
- 1. Definition: Singular value decomposition (SVD)
 - 一个 real m×n 矩阵A的 singular value decomposition (SVD) 的形式为:
 A = U \(\Sum V \) \(\Tag{T} \)

其中,

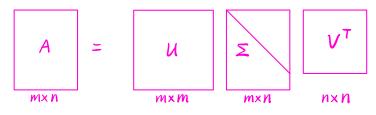
- ① U∈R^{m×m} 的 columns 'Ui 被称为 left singular vectors (左奇异向量)
- D V∈R^{n×n}的 columns 'Vi 被称为 right singular vectors (右對异向量)
- $\Sigma \in \mathbb{R}^{m \times n}$ $\lambda diagonal matrix with$

$$\nabla ij = \begin{cases}
0 & \text{ } \vec{k} \neq j \\
\nabla i \geq 0 & \text{ } \vec{k} \neq j
\end{cases}$$

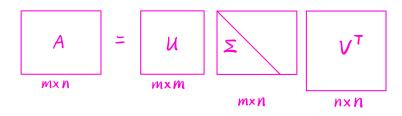
对角线元素 oi 为A的 singular values (奇异值),且通常为 ordered:

- 注: ① 若 U=V, 则 SVD 等价于 eigendecomposition (仅仅 m=n 还不能得出该结论)
 - ② SVD的大致形式为:

Case 1: m>n



Case 1: m<n



2、Theorem: SVD 的 existence 与 construction

所有 real matrix A ∈ R^{m×n} 场有 SVD: A = UΣV^T(*1,且

- O V Θ columns A $AA^T \in R^{m \times m}$ Θ eigenvectors
- D V G columns A $A^TA \in \mathbb{R}^{n \times n}$ G eigenvectors
- B singular values σ_i = √λ_i , i=1,--, P,其中λ_i,--,λp为 AAT 诺m<n)或 A^TA (若m>n) (AA^T与 A^TA 中维度较小的)的 eigenvalues
- 证明》(此处不用讨论 m 5 n 谁大, 因为 A^TA 5 A A^T 相差的特征值全为 D) 该证明非常 constructive,即我们先根据 A A^T 的 eigen decomposition 求出 U和 工, 再根据目标构造出 V.

- 由于 AA^T 为 symmetric 且 positive semi-definite ($x^TA^TAx = ||Ax||^2 \ge D$, $\forall x$), 有 $AA^T = U \wedge U^T$, U 为 orthorogonal matrix (实对称矩阵一定图可对角化) 且 $\Lambda = diag(\lambda_1, \dots, \lambda_m)$ with $\lambda_1 \ge \dots \ge \lambda_r > 0 = \lambda_{r+1} = \dots = \lambda_m$ (牡廷矩阵特征值非负) 定义 $\Sigma := \sqrt{\Lambda} = diag(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_m})$
- D 第一种情况: r=m (注:此时一定有 m≤n,否则一定有 λ;=D)
 由于此时 U与∑可逆, 为了使 A=U∑V^T, 直接 构造 V 为:
 V:= A^TU∑⁻¹

接下来负需 check:

- 図 弟二种情况: r<m (注:此时不一定有 m∈n,但有 r∈min{m·n},仅需保证 Σ∈R^{m×n}) 此时 U与 Σ不可逆, 无法直接构造 V.
 - · 焰 U partition为 $U=[U_1,U_2]$,其中 $U_1 \in \mathbb{R}^{m \times r}$, $M \in \mathbb{R}^{m \times r}$, $M \in \mathbb{R}^{m \times r}$, $M \in \mathbb{R}^{m \times r}$.
 - · 杨逡 $V_i := A^T U_i \hat{\Sigma}^T \in \mathbb{R}^{n \times L \times n}$ 描了来我们可以证得;
 - $O V_i^T V_i = I$

$$V_{i}^{T}V_{i} = \widetilde{\Sigma}^{-1}U_{i}^{T}AA^{T}U_{i}\widetilde{\Sigma}^{-1}$$

$$= \widetilde{\Sigma}^{-1}U_{i}^{T}U_{i}\widetilde{\Sigma}^{2}U_{i}^{T}U_{i}\widetilde{\Sigma}^{-1}$$

$$(AA^{T} = U\Lambda U^{T} = [U_{i}U_{i}][\widetilde{\Sigma}^{2} Q][U_{i}U_{i}]^{T} = U_{i}\widetilde{\Sigma}^{2}U_{i}^{T})$$

$$= \hat{\Sigma}^{-1} \hat{\Sigma}^{2} \hat{\Sigma}^{-1}$$
$$= 7$$

$$U_{1}\widetilde{\Sigma}V_{1}^{T} = U_{1}\widetilde{\Sigma}\widetilde{\Sigma}^{-1}U_{1}^{T}A$$

$$= U_{1}U_{1}^{T}A$$

$$(U^{\mathsf{T}}U = \begin{bmatrix} U_1^{\mathsf{T}} \\ U_2^{\mathsf{T}} \end{bmatrix} [U_1 U_2] = \begin{bmatrix} U_1^{\mathsf{T}}U_1 & U_1^{\mathsf{T}}U_2 \\ U_2^{\mathsf{T}}U_1 & U_2^{\mathsf{T}}U_2 \end{bmatrix} = I \quad \Rightarrow \quad U_1^{\mathsf{T}}U_2 = D$$

- $\Rightarrow V_{\lambda}^{\mathsf{T}} A A^{\mathsf{T}} U_{\lambda} = V_{\lambda}^{\mathsf{T}} U_{1} \widetilde{\Sigma}^{\lambda} U_{1}^{\mathsf{T}} U_{\lambda} = 0$
- \Rightarrow trace $|V_2^T A A^T U_2| = ||A^T U_2||_F^2 = D$
- $\Rightarrow U^{T}A = D$

$$UU^{T} = U_{1}U_{1}^{T} + U_{2}U_{2}^{T} = I \Rightarrow U_{1}U_{1}^{T} = I - U_{2}U_{2}^{T}$$

$$\Rightarrow U_1 U_1^{\mathsf{T}} A = (I - U_2 U_2^{\mathsf{T}}) A = A - U_2 U_2^{\mathsf{T}} A = A)$$

· 构造
$$V := [V_1, V_2] \in \mathbb{R}^{n \times n} (V \in \mathbb{R}^{n \times (n-r)}$$
 任选,确保 $V \not \supset \text{ orthorgonal})$
$$\Sigma := \begin{bmatrix} \widetilde{\Sigma} & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{m \times n}$$

因此有:

$$V^{T}V = I$$

$$U\Sigma V^{T} = U_{1}\widehat{\Sigma} V_{1}^{T} = A$$

3. Definition: thin SVD (Economy size)

全r为 matrix A的非零 singular values 数, 那

则我们有:
$$A = [U_1 U_2] r \{ \begin{bmatrix} \tilde{\Sigma} & D \\ D & D \end{bmatrix} \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} \} n-r$$

其中: UieRmxr, UzeRmx(m-r), VieRnxr, VzeRnx(n-r), 至=diag(oi,--,or)

$$A = U_1 \widetilde{\Sigma} V_1^T$$

4 对 Left & Right singular vectors 的理解

$$A = U \Sigma V^{\mathsf{T}} \iff \begin{cases} A V = U \Sigma \\ V^{\mathsf{T}} A = \Sigma V^{\mathsf{T}} \end{cases}$$

图 11 求下述矩阵的 SVD:

$$A = \left[\begin{array}{ccc} 1 & 0 & -1 \\ 1 & 1 & 0 \end{array} \right]$$

① Step 1: 计并 ATA 与 AAT中维度更小 (更易于计算) 的一个

$$AA^{\mathsf{T}} = \begin{bmatrix} 1 & 0 & -1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ -1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

D Step 2: 计算ATA 或AAT 的特征值, 中出 Σ

$$\det(AA^{T}-\lambda I) = (2-\lambda)^{2}-1 = 4-4\lambda+\lambda^{2}-1 = (\lambda-1)(\lambda-3) = 0$$

$$\Rightarrow \Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{bmatrix}$$

D Step 3: 计算 ATA 或 AAT 的特征向量, 本出 V 或 U

•
$$AA^{\mathsf{T}} - \lambda_1 \mathbf{1} = \mathbf{0} \iff \begin{bmatrix} -1 & 1 & | \mathbf{0} \\ 1 & -1 & | \mathbf{0} \end{bmatrix} \iff \begin{bmatrix} 1 & -1 & | \mathbf{0} \\ \mathbf{0} & \mathbf{0} & | \mathbf{0} \end{bmatrix}$$

取自由未知量 $X_2=1$,有 eigenvector $[1,1]^T$ Normalize 后有: $[u_1=\frac{1}{12}[1,1]^T$

$$AA^{\mathsf{T}} - \lambda_2 \mathbf{I} = \mathbf{0} \iff \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \end{bmatrix} \iff \begin{bmatrix} 1 & 1 & 0 \\ \mathbf{0} & \mathbf{0} & 0 \end{bmatrix}$$

取自由未知量 $X_2=1$, 有 eigenvector $[-1,1]^T$ Normalize 后有: $U_2=\frac{1}{12}[-1,1]^T$

$$\Rightarrow U = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$$

O Step 4: 利用A=UΣVT 非解另一个 orthorgonal matrix

 $A = U\Sigma V^{T} \iff A^{T} = V\Sigma U^{T} \iff V = A^{T}U\Sigma^{-1}$ $\Rightarrow V = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ -1 & 0 \end{bmatrix} \xrightarrow{\frac{1}{\sqrt{12}}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{13}}{3} & 0 \\ 0 & 1 \end{bmatrix}$ $= \frac{1}{\sqrt{16}} \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \sqrt{3} \end{bmatrix}$

$$= \frac{1}{\sqrt{b}} \left[\begin{array}{c} > 0 \\ 1 \sqrt{3} \\ -1 \sqrt{3} \end{array} \right]$$